Beer recommendation system

```python
# Imports and required packages
import pandas as pd
import numpy as np
import math
import matplotlib.pyplot as plt
import seaborn as sns
from collections import Counter
import plotly.express as px
import statsmodels
import warnings
warnings.filterwarnings("ignore",category=plt.cbook.mplDeprecation)

plt.rcParams["figure.figsize"] = (14,7)
sns.set_theme(style="whitegrid")

# Data
# Source: https://www.kaggle.com/rdoume/beerreviews
df = pd.read_csv(r"beer_reviews.csv")

# Data shape and number of unique values per column
print(df.shape)
print(df.nunique())
```

```
(1586614, 13)
brewery_id               5840
brewery_name             5742
review_time           1577960
review_overall             10
review_aroma                9
review_appearance          10
review_profilename      33387
beer_style                104
review_palate               9
review_taste                9
beer_name               56857
beer_abv                  530
beer_beerid             66055
dtype: int64
```

```python
# Check for null values
print(df.isnull().sum())

# Drop null row values
df = df.dropna()

# Percent of data missing `beer_abv` values, having the highest null
count
print("\nPercent Null Values of `beer_abv` column:", round(67785 /
1586614 * 100, 2),"%")
```

```
brewery_id                0
brewery_name             15
review_time               0
review_overall            0
review_aroma              0
review_appearance         0
review_profilename      348
beer_style                0
review_palate             0
review_taste              0
beer_name                 0
beer_abv              67785
beer_beerid               0
dtype: int64
```

```
Percent Null Values of `beer_abv` column: 4.27 %
```

```
# check for same user review for a beer
dfrows = df.shape[0]
df = df.sort_values('review_overall', ascending=False)
# Keep the highest rating from each user and drop the rest
df = df.drop_duplicates(subset= ['review_profilename','beer_name'],
keep='first')
# Percent of data that are duplicates
print("Percent of Duplicate Values:", round((dfrows - df.shape[0])/
dfrows * 100, 2),"%")
```

```
Percent of Duplicate Values: 1.46 %
```

```
# Beer style distribution
tempC = Counter(df['beer_style'])
tempC = sorted(tempC.items(), key=lambda x:x[1])
sortedC = dict(tempC)
labels = []
for i in sortedC:
    if sortedC[i] < 19354 :
        labels.extend([""])
    else:
        labels.extend([i])
#labels = (list(sortedC.keys()))
#labels.extend([""]* 84)
df['review_profilename'] = df['review_profilename'].factorize()[0]
histplot = plt.pie(sortedC.values(), startangle=348, labels=labels)

plt.suptitle('Beer style distribution')
plt.show()
```

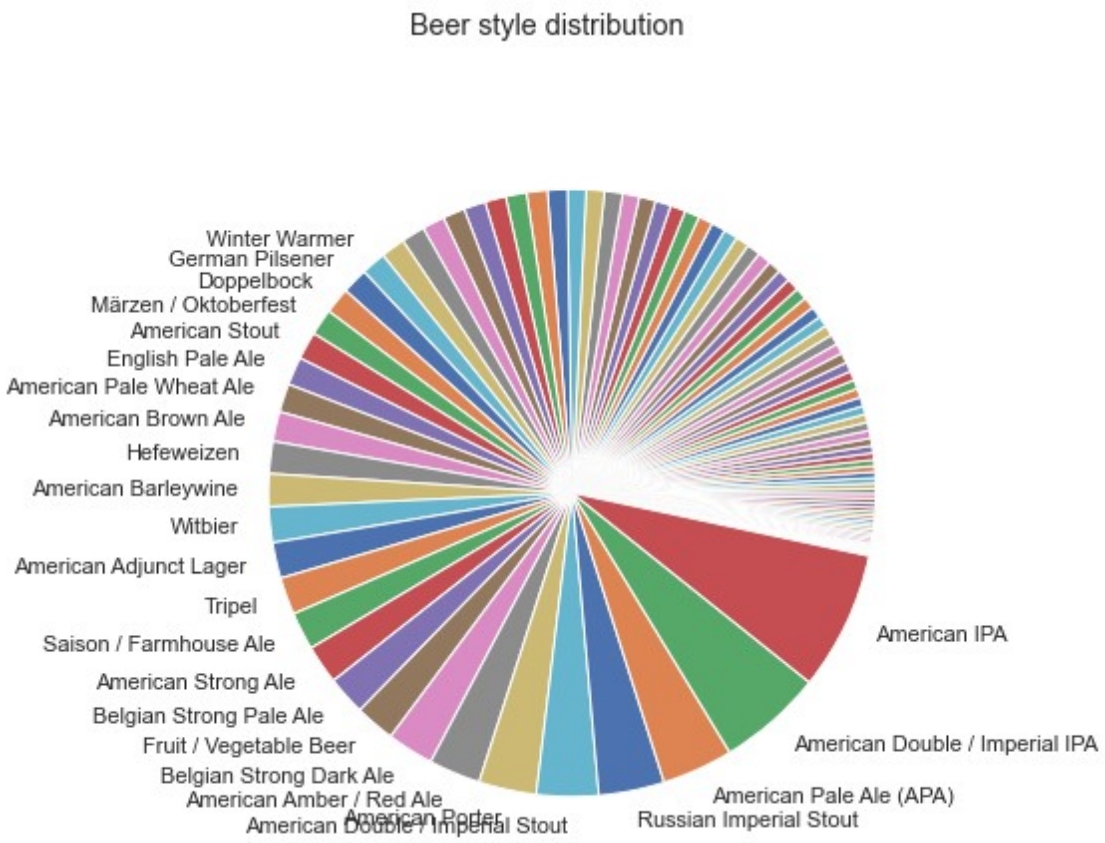

יש פיזור סגנונות, ואין סגנון אחד אשר לוקח חלק גדול מדי.

```
# Distribution of reviewers by the amount of contributed reviews
histplot =
plt.hist(Counter(df['review_profilename']).values(),stacked=True)
plt.yscale('log')
plt.ylabel('number of reviewers')
plt.xlabel('reviews per idividual')

plt.suptitle('Distribution of reviewers by the amount of their
reviews')
plt.show()
```

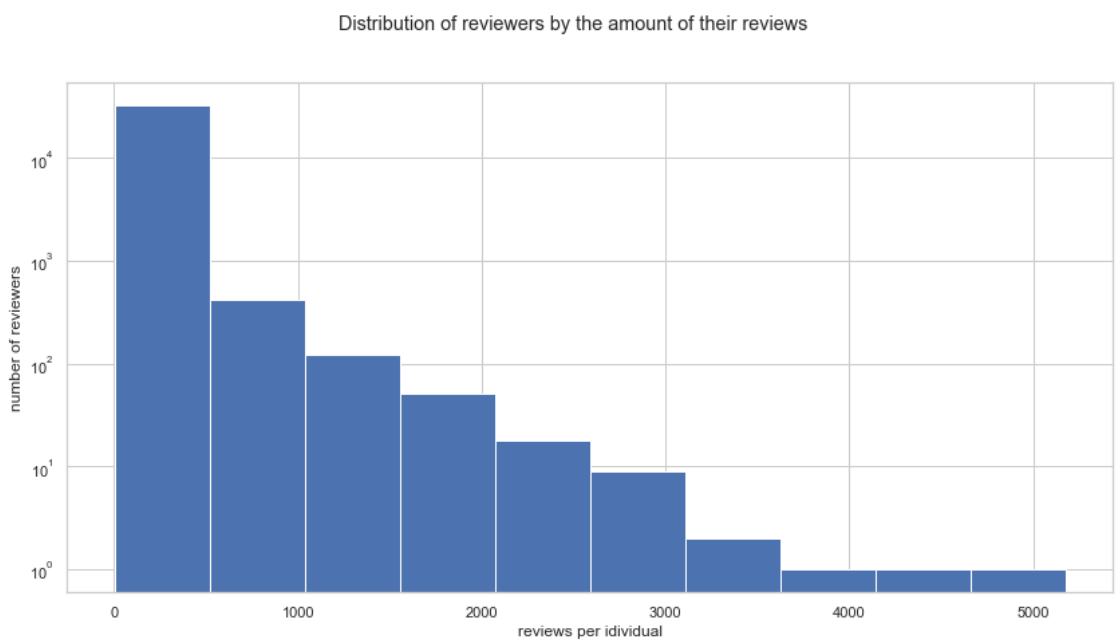

נראה כי רוב היוזרים סיפקו בסביבות ה10 ביקורות ומעט יוזרים סיפקו כמות גדולה של . ביקורות .נסיק כי זה משקף פיזור ריאליסטי של אדם שמספק ביקורות על בירות, רוב האנשים יביאו ביקורת על כמות בירות קטנה ומעט אנשים (אשר מתעניינים בבירה) יוכלו להביא יותר ביקורות

```
# Distribution of beers/breweries by the amount of reviews
f, ax = plt.subplots( 1, 2)
plt.setp(ax, ylabel=('number of reviews'))

# Breweries plot
ax[0].hist(Counter(df['brewery_name']).values(), stacked=True)
ax[0].set_yscale('log')
ax[0].set_xlabel('reviews per brewery')
ax[0].set_ylabel('number of breweries')

# Beers plot
ax[1].hist(Counter(df['beer_name']).values(),stacked=True)
ax[1].set_yscale('log')
ax[1].set_xlabel('reviews per beers')
ax[1].set_ylabel('number of beers')

plt.suptitle('Distribution of breweries/beers by the amount of
reviews')
plt.show()
```

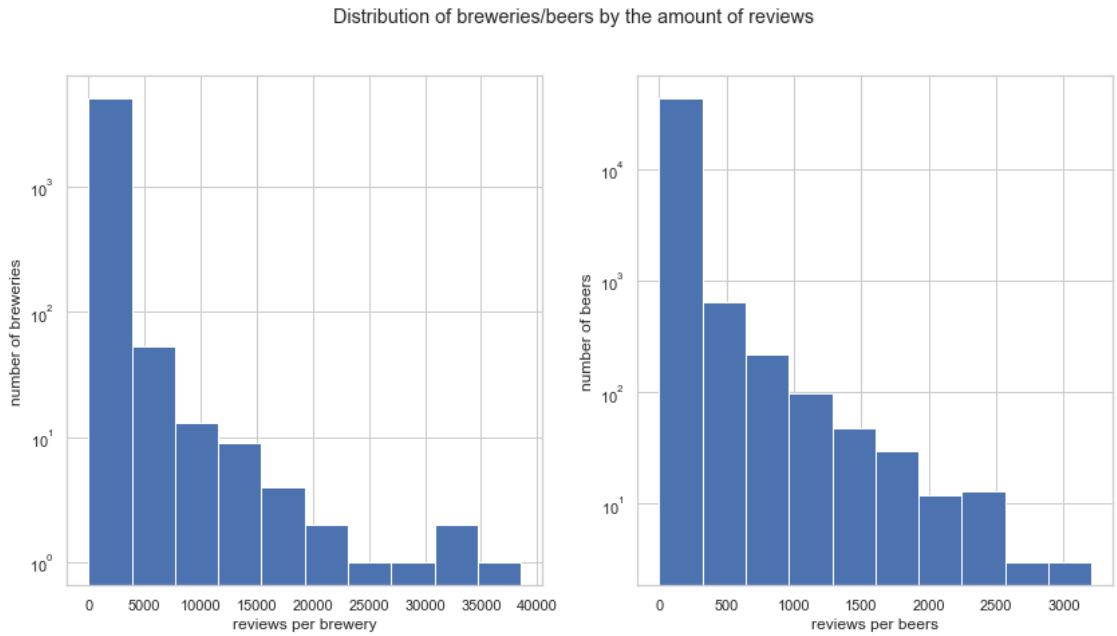

נראה כי יש מעט בירות ומבשלות אשר יש להן כמות ביקורות גדולה, כנראה מותגים ידועים או נגישים יותר.

```
# # Distribution and means display for scores given by reviews
ax =
sns.boxplot(data=df[['review_aroma','review_appearance','review_palate
','review_taste','review_overall']], palette="Set2", linewidth=2,
notch=True)
ax.set_yticks(np.arange(0, 5.25, 0.5))

plt.suptitle('Distribution and means display for scores given by
reviews')
plt.show()
```

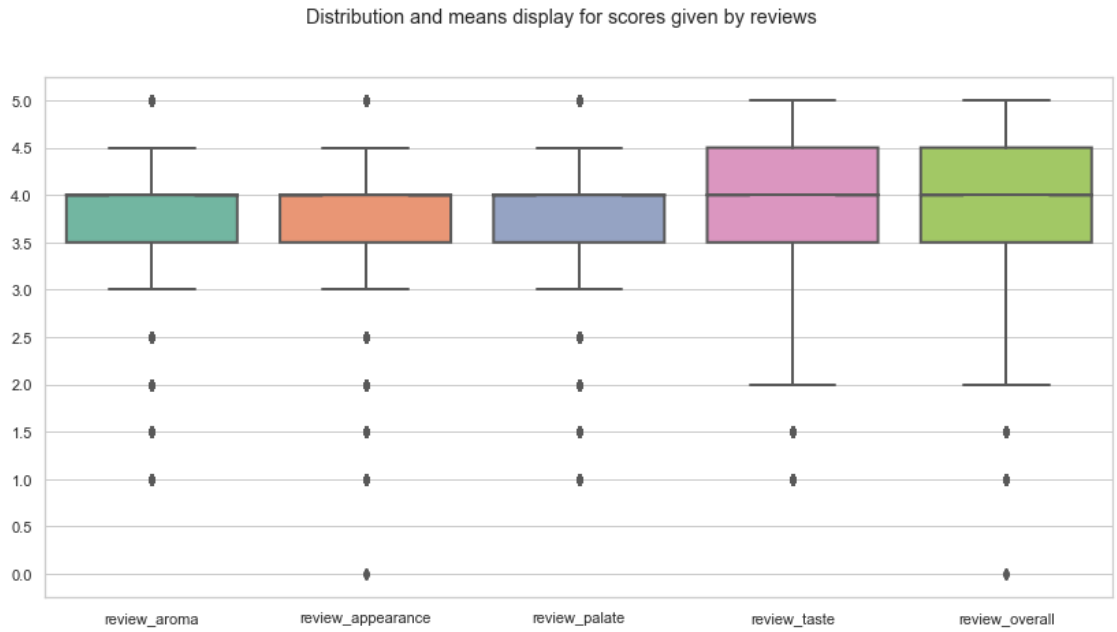

נראה כי הדירוגים מתרכזים סביב דירוג 4 בכל הקטגוריות, אם כי יש דירוגים של 0 או 1 בכלל הקטגוריות.

```
# Correlation between every category including beer ABV and overall score
axislabels = ['review overall', 'review aroma', 'review appearance', 'review palate', 'review taste', 'beer ABV']
ax = sns.heatmap( df[ [ 'review_overall', 'review_aroma', 'review_appearance', 'review_palate', 'review_taste', 'beer_abv' ] ].corr(), center= 0.25, vmin = 0, vmax = 1, annot=True)

plt.suptitle( "Correlation heatmap" )
plt.show()
```

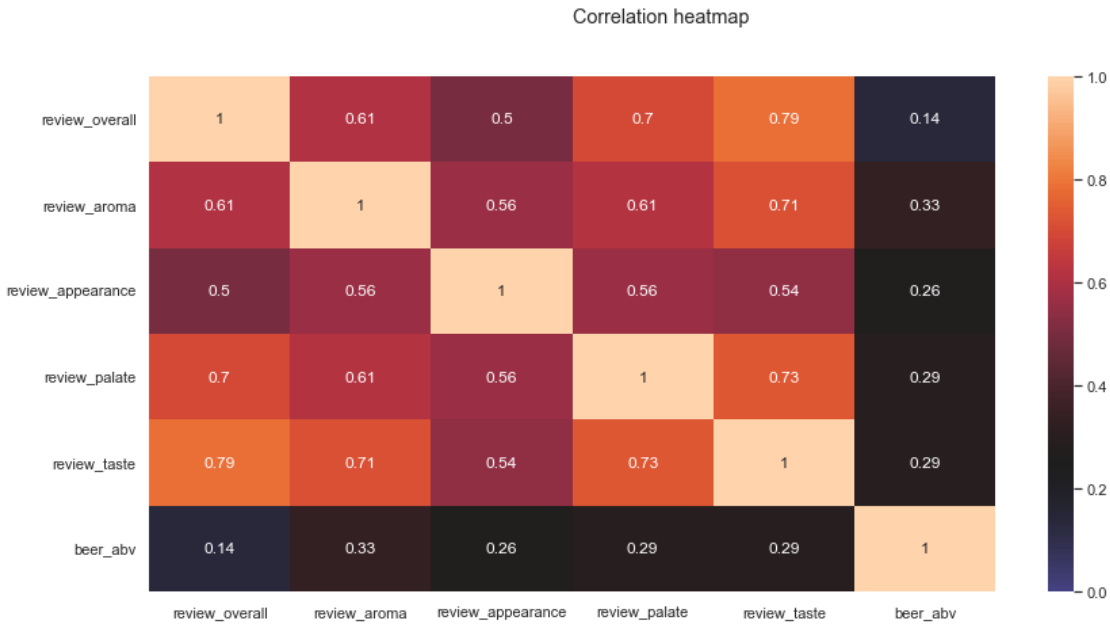

גרף זה מראה לנו את היחס בין כל זוג קטגוריות נראה שמקבלים קשר חזק יותר עבור . קטוגוריות של טעם, תוצאה שהינו מצפים שתתקבל .לעומת זאת, הקשר בין אחוזי האלכוהול לדירוג הסופי הינו קטן מאוד וזוהי תוצאה שאינה נובעת מהיגיון או אפילו סותרת אותו

```
# Correlation between each catagory and the overall rating
overall_means = df.loc[:,
['review_aroma','review_appearance','review_palate','review_taste','re
view_overall']]
overall_means = overall_means.groupby('review_overall').mean()
overall_means = pd.DataFrame(data=overall_means)
overall_means =
overall_means.sort_values(by=['review_overall'],ascending=False).reset
_index()
overall = overall_means["review_overall"]

f, ax = plt.subplots( 2, 2, sharex = 'col', sharey = 'row', figsize =
( 14, 7 ) )
plt.setp(ax, xlim=(-0.5,5.5), ylim=(-0.5,5.5),
xticks=([0,0.5,1,1.5,2,2.5,3,3.5,4,4.5,5]), yticks=([0,1,2,3,4,5]))

# Appearance plot
ax[0][0].scatter(x="review_appearance",y="review_overall",
data=overall_means,)
z = np.polyfit(overall, overall_means["review_appearance"] ,1)
p = np.poly1d(z)
ax[0][0].plot(overall,p(overall),"r--")
ax[0][0].set_title( 'appearance v overall' )

# aroma plot
ax[0][1].scatter(x="review_aroma",y="review_overall",
data=overall_means,)
```

```
z = np.polyfit(overall, overall_means["review_aroma"] ,1)
p = np.poly1d(z)
ax[0][1].plot(overall,p(overall),"r--")
ax[0][1].set_title( 'aroma v overall' )

# palate plot
ax[1][0].scatter(x="review_palate",y="review_overall",
data=overall_means,)
z = np.polyfit(overall, overall_means["review_palate"] ,1)
p = np.poly1d(z)
ax[1][0].plot(overall,p(overall),"r--")
ax[1][0].set_title( 'palate v overall' )

# taste plot
ax[1][1].scatter(x="review_taste",y="review_overall",
data=overall_means,)
z = np.polyfit(overall, overall_means["review_taste"] ,1)
p = np.poly1d(z)
ax[1][1].plot(overall,p(overall),"r--")
ax[1][1].set_title( 'taste v overall' )

plt.suptitle( "Correlation between each catagory and the overall
rating" )
plt.show()
```

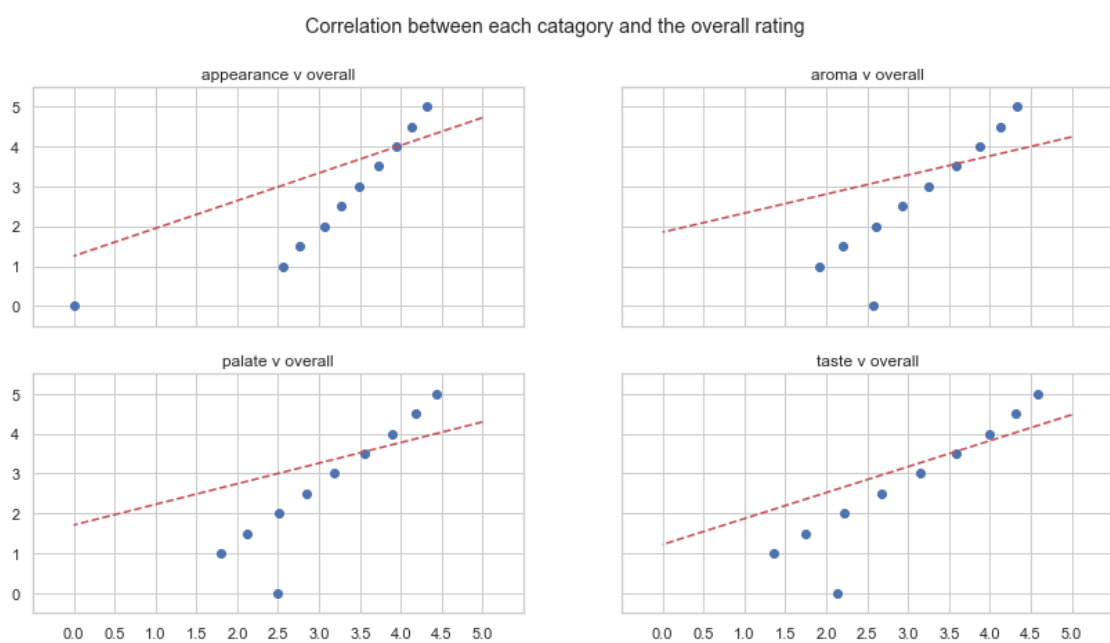


```
# Correlation between beer ABV and overall beer score
abv_overall = df.loc[:,['beer_abv','review_overall']]
abv_overall = abv_overall.groupby('beer_abv').mean()
abv_overall = pd.DataFrame(data=abv_overall)
abv_overall =
abv_overall.sort_values(by=['beer_abv'],ascending=False).reset_index()
```

```
plt.scatter(abv_overall['beer_abv'],abv_overall['review_overall'])
plt.xlabel('beer abv')
plt.ylabel('overall rating')

plt.suptitle('Correlation between beer ABV and overall beer score')
plt.show()
```

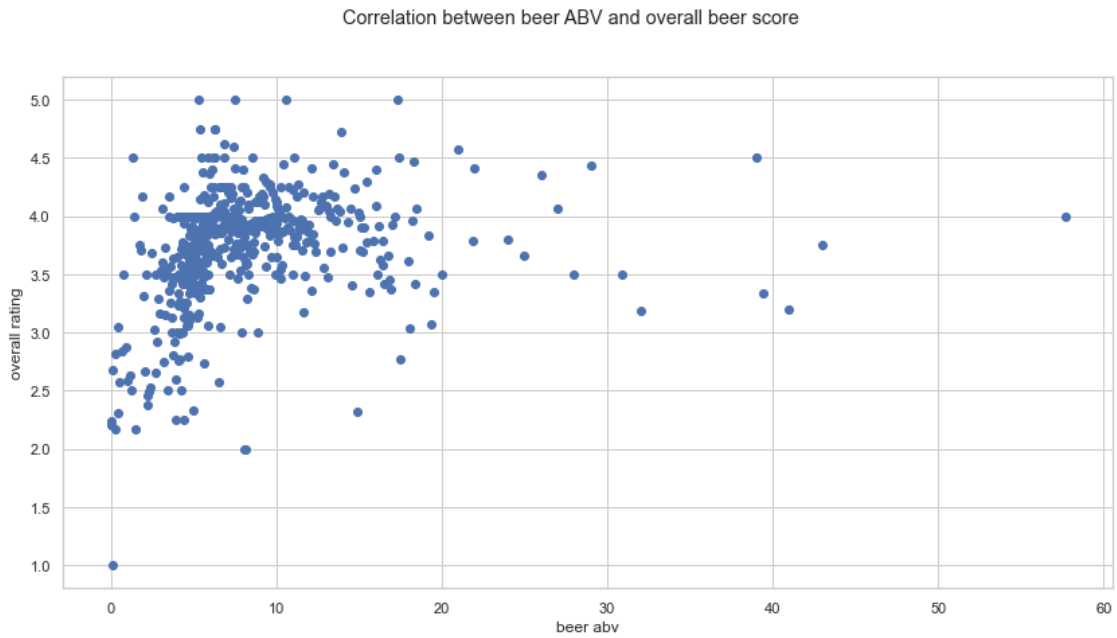

פיזור של אחוזי אלכוהול של בירה לעומת הדירוג הסופי שקיבלה .לא ניתן לקבל תשובה חד .
משמעית מהגרף בלבד

הסבר על המערכת

אופן פעולת המערכת:

- חלונית הכניסה:

- יש להזין דירוגי בירה של המשתמש (אפשר גם לא להזין כלום).

יש לבחור ממגוון הבירות שקיימות ברשימה ולבחור דירוג מ0 ועד 5 ולסיים הזנה עם כפתור הadd.
ליד הכפתור ישנו מספר המסמל כמה דירוגים הוזנו.

- לבסוף יש ללחוץ על get results והחלונות תתעדכן עם הבירות שהמערכת הציע:

- יש ללחוץ על כפתור ה 'exit' כדי לצאת מהחלונית ולסיים את ריצת התוכנית.
- בכל רגע ניתן ללחוץ על כפתור ה reset כדי לחזור למסך הראשון ולאפס את הקלט.

ארכיטקטורת המערכת:

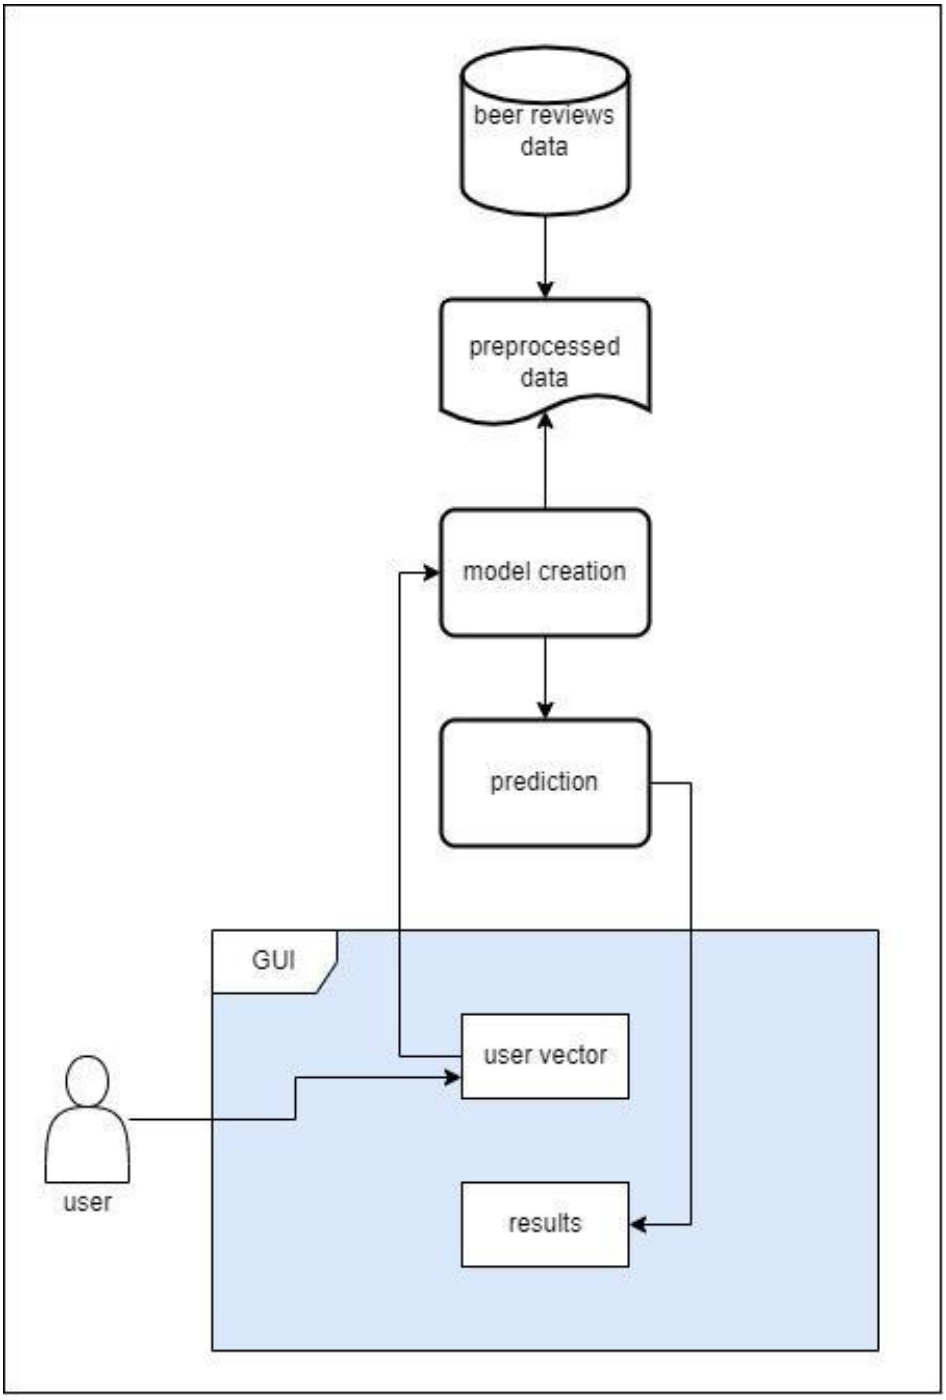

אופי ייצוג המידע ועיבוד מקדים:

מהקובץ המקורי יצרנו קבצים חדשים:

- Data – טבלה המקורית לאחר עיבוד מקדים.
- Table – מילון של טבלאות המרה.
- Users – טבלה המכילה את כל המשתמשים במערכת כאשר כל משתמש מיוצג כווקטור של דירוגיו הממוצעים לכל סגנון בירה.
- Items – טבלה המכילה את כל הבירות במערכת כאשר כל בירה מיוצגת כווקטור של ממוצעי דירוגיה של הבירה.

הדמיון מחושב על ידי cosine similarity.

אופי המודל:

המערכת הינה מערכת המלצה היברידית המשלבת גם מודל שיתופי וגם מבוסס תוכן.
המערכת מספקת עבור המשתמש תוצאות גם עבור מודל שיתופי וגם מבוסס תוכן.
במידה וישנו משתמש ללא ביקורות (cold start), המערכת תחזיר topN בירות לפי דירוג.

מודל הלמידה שנבחר:

בחרנו לממש מודל KNN.
המימוש גם עבור שכנויות בין המשתמשים וגם עבור שכנויות בין הבירות.
בחרנו בKNN מכיוון שבעינינו זו הייתה הבחירה הטבעית לאחר המרת המשתמשים/בירות לוקטורים, ניתן לדרג קירוב לכל וקטור בשימוש ע"י KNN.

מדדי הערכה וניסויים

מדדי ההערכה שנבחרו:

השתמשנו במדד Leave one out.
תחילה הערכנו את המודל עבור סיווג ישיר, כלומר האם המערכת הציעה את הבירה שהחסרנו.
קיבלנו אחוזי הצלחה נמוכים מאוד.
לאחר מכן שינינו את הסיווג לבדיקה האם סגנון הבירה זהה לסגנון הבירה שהחסרנו.
עבור ניסוי זה קיבלנו תוצאות טובות יותר (מעל 60%).
החלטנו בנוסף להוסיף לסיווג בדיקה האם מוצעת אותה המבשלת.
בניסוי זה קיבלנו תוצאות טוב אף יותר (בסביבות ה65%).

תוצאות הניסויים ומסקנות:

מהניסויים הראשונים, קיבלנו תוצאות נמוכות מאוד.
אנחנו משערים כי חוסר המאפיינים שיש במאגר הנתונים שלנו עבור כל בירה יוצר קושי באפיון מדויק לבירה, מה שגורם להצעות שאינן בהכרח הבירה שהחסרנו.
בנוסף אנחנו משערים כי עבור קשרים בין משתמש למשתמש, השוני של המיקום של שתי המשתמשים יוצר בעיה.
לדוגמא, משתמש אחד גר בישראל ומשתמש שני גר בגרמניה.
שתי המשתמשים יכלו לדרג בירה פופולרית במשותף, המשתמש בגרמניה יכול לדרג בירה שאינה ברת השגה עבור המשתמש בשני שגר בישראל ולהפך.
עבור דוגמא זו שתי המשתמשים קרובים זהותית, אך יש להם דירוג עבור בירה "אקסקלוסיבית", ובמדד leave-one-out היינו מקבלים הצעה עבור בירה לא נכונה.

הסקנו שבכדי לכפר על חוסר במאפיינים, גם עבור משתמש וגם עבור בירה, ננסה להרחיב ולפשט את המטרה שלנו, ונבדוק האם ההצעה נכונה עבור מבשלת או סגנון הבירה.
הסיבה לכך שחשבנו כי פעולה זו תשפר את המערכת וגם תשאיר אותה רלוונטית היא:
1. מכתבות ומאמרים שקראנו אנשים נוטים לשתות בירה מאותו סגנון.
לדוגמא אדם ששותה ויינשטפן, שותה גם פאולנר, (בירת חיטה מעוננת).
ואדם ששותה היינקן, שותה גם קרלסברג, (לאגר).
2. בנוסף עבור אדם עם ביקורת עבור בירה מסוימת, יש סיכוי גבוה שיש לו גם ביקורת עבור בירה נוספת מאותה המבשלת, מכיוון שאנשים נוטים לקחת משו שנשמע מוכר גם כאשר הם מחליטים לנסות משו חדש.
לדוגמא ויינשטפן וויינשטפן ויטוס.

סיכום

סיכום הפרויקט בכמה משפטים:

פיתחנו מערכת המלצה לבירות.
המערכת היא מערכת המלצה משולבת content based וגם collaborative.
המערכת מכילה ממשק גרפי אשר המשתמש מזין את הביקורות שיש לו עבור בירות (אם יש כאלו)
ומקבל המלצה על בירות שהמערכת מתאימה לו.

אתגרים שנתקלנו בהם וכיצד התגברנו עליהם:

האתגר המרכזי שנתקלנו בו הוא הדרך בה נבחר את הפיצ'רים לוקטורים בשני השיטות, למשתמשים ולבירות. ניסינו מספר גישות, עבור המשתמשים בחרנו לייצג כל משתמש ע"י ממוצעי הדירוגים שלו לכל סגנון בירה, ועבור הבירות נתקלנו בבעיה נוספת, כך שרוב הפיצ'רים שיש לנו עבור בירה, לא יכולים לתרום לנו לדמיון כלשהו בין בירות, הפיצ'ר היחיד שניתן להשתמש בצורה שתתרום הינו אחוזי האלכוהול, שאר הפיצ'רים כמו מבשלת הבירה הינו נתון שקשה להשתמש בו בדמיון, מצד אחד ניתן להגיד שזוג בירות מאותה מבשלה כביכול אמורות להיות דומות, אך זה יגרום למודל מאוד עני, שמסתכל על הבירות בצורה ממוקדת מידי, כאשר בפועל אנו נרצה שהמודל יתאים בין בירות דומות לפי מאפיינים שלא קשורים לאיפה יוצרה או ע"י מי, לכן בסופו של דבר הצד של הCBF במערכת שלנו הינו "חלש" מאחר ואנחנו משתמשים במאפיינים מאוד סובייקטיבים פר משתמש, בעצם הדירוג של משתמש על בירה כלשהי. בגלל הבחירה בדאטא הנתון, לא הייתה לנו אופציה ל"חזק" צד זה במודל שלנו.

נספח

נתונים - https://www.kaggle.com/rdoume/beerreviews

כלים וספריות:

1. שפת תכנות: Python
2. עבודה עם נתונים: pandas, Numpy, pickle, os,
3. עבודה עם גרפים: matplotlib, seaborn, ploty, statsmodel
4. ספריות עבור GUI: tkinter, PIL, urllib